

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN - ĐẠI HỌC QUỐC GIA TP HCM

KHOA CÔNG NGHỆ THÔNG TIN

CSC14005 - Nhập môn học máy



ĐỒ ÁN

VIETNAMESE OCR

Lớp: 23KHDL1

Sinh viên:

Lê Quang Phúc - 23127102

Nguyễn Quang Đăng Khoa - 23127212

Đoàn Thành Phát - 23127241

Trần Tiến Cường - 23127332

Trần Hữu Nhân - 23127442

Giảng viên hướng dẫn:

Thầy Bùi Tiến Lên

Thầy Lê Nhật Nam

Thầy Võ Nhật Tân

25 tháng 3 năm 2026

Mục lục

BẢNG PHÂN CÔNG	1
1 Giới thiệu bài toán	2
2 Phương pháp và nguồn thu nhập dữ liệu	2
2.1 Nguồn dữ liệu	2
2.2 Phương pháp thu nhập	2
2.2.1 Dữ liệu có sẵn	2
2.2.2 Dữ liệu mở rộng	3
2.2.3 Không gian lưu trữ và cấu trúc dữ liệu	4
3 Quy trình làm sạch và tiền xử lý dữ liệu	5
3.1 Quy trình kiểm tra sự nhất quán	5
3.2 Quy trình xử lý dữ liệu bị thiếu	5
4 Đảm bảo chất lượng dữ liệu	5
5 Lưu trữ và quản lý dữ liệu	6
5.1 Dữ liệu gốc	6
5.2 Dữ liệu huấn luyện	7
6 Phân tích, khám phá dữ liệu (EDA)	8
6.1 Thống kê mô tả	8
6.1.1 Tổng quan bộ dữ liệu	8
6.1.2 Phân tích ký tự	8
6.1.3 Phân tích từ vựng	9
6.1.4 Phân tích độ phân giải ảnh	10
6.1.5 Phân tích độ sáng/tối và chất lượng ảnh	10
6.2 Kiểm tra chất lượng dữ liệu	10
6.3 Khám phá dữ liệu	11
6.3.1 Số lượng ảnh	11
6.3.2 Phân bố theo độ dài nhãn	12

6.3.3	Tỉ lệ ký tự có dấu	13
6.3.4	Phân tích ký tự	14
6.3.5	Độ sáng và độ nét của ảnh	16
6.3.6	Một số dữ liệu mẫu	18
TÀI LIỆU		19

Danh sách bảng

1	Phân công nhiệm vụ và đánh giá thành viên	1
2	Đánh giá mức độ hoàn thành công việc	1
3	Thống kê chi tiết bộ dữ liệu UIT-HWDB	3
4	Cấu hình thông số kỹ thuật quá trình Fine-tuning LoRA	6
5	Thống kê theo từng bộ dữ liệu	8
6	Thống kê top10 ký tự phổ biến nhất	9
7	Thống kê top10 từ vựng phổ biến nhất	9
8	Các thông số về độ phân giải ảnh	10
9	Các thông số về độ sáng/tối ảnh	10

Danh sách hình vẽ

1	Ảnh cắt theo từng dòng	3
2	Số lượng ảnh theo loại dataset	11
3	Phân bố độ dài label	12
4	Tỉ lệ ký tự tiếng Việt có dấu	13
5	Top10 ký tự xuất hiện nhiều nhất	14
6	Top10 ký tự tiếng Việt (có dấu)	15
7	50 từ phổ biến nhất	15
8	Phân bố độ sáng trung bình	16
9	Phân bố độ nét ảnh	17
10	Một số dữ liệu mẫu	18

BẢNG PHÂN CÔNG

GitHub: [IntroToML Repository](#).
Kế hoạch làm việc: [IntroToML Timeline](#).
Không gian lưu trữ: [IntroToML Dataset](#)

STT	Họ và tên	MSSV	Tác vụ đảm nhiệm	Hoàn thành
1	Lê Quang Phúc	23127102	Tiền xử lý dữ liệu	100%
2	Nguyễn Quang Đăng Khoa	23127212	Khám phá dữ liệu & Viết báo cáo	100%
3	Đoàn Thành Phát	23127241	Khám phá dữ liệu	100%
4	Trần Tiến Cường	23127332	Tiền xử lý dữ liệu & Viết báo cáo	100%
5	Trần Hữu Nhân	23127442	Tổ chức dữ liệu & Viết báo cáo	100%

Bảng 1: Phân công nhiệm vụ và đánh giá thành viên

STT	Công việc	Mức độ hoàn thành
1	Tổ chức không gian lưu trữ dữ liệu	100%
2	Thực hiện tiền xử lý dữ liệu	100%
3	Thực hiện khám phá dữ liệu	100%
4	Hoàn thành báo cáo tiến độ lần 1	100%

Bảng 2: Đánh giá mức độ hoàn thành công việc

1 Giới thiệu bài toán

Bài toán học máy mà nhóm hướng tới là xây dựng hệ thống nhận dạng ký tự quang học (OCR) chuyên biệt, tập trung tối ưu hóa khả năng nhận dạng tiếng Việt, đặc biệt là về hình ảnh có chữ viết tay. Mục tiêu trọng tâm của bài toán là chuyển đổi các dữ liệu ở định dạng hình ảnh phi cấu trúc (như tài liệu quét hoặc ảnh chụp văn bản giấy) thành dữ liệu văn bản.

2 Phương pháp và nguồn thu nhập dữ liệu

2.1 Nguồn dữ liệu

Chất lượng, số lượng và độ đa dạng của dữ liệu được xem là yếu tố tiên quyết quyết định hiệu năng của mô hình. Đối với bài toán OCR tiếng Việt, thách thức không chỉ nằm ở việc nhận diện ký tự mà còn phải xử lý được sự thay đổi vô cùng lớn của nét chữ viết tay cá nhân cùng hệ thống dấu thanh. Do đó, nhóm không chỉ dựa vào một nguồn dữ liệu duy nhất mà kết hợp giữa nhiều nguồn dữ liệu chuẩn và dữ liệu thực tế tự thu thập thêm để đảm bảo mô hình có khả năng tổng quát hóa tốt nhất, bao gồm:


- **Dữ liệu có sẵn:** bộ dữ liệu [UIT-HWDB](#) [1]
- **Dữ liệu mở rộng:** dữ liệu do nhóm chuẩn bị.

2.2 Phương pháp thu nhập

2.2.1 Dữ liệu có sẵn

Để giải quyết bài toán nhận dạng chữ viết tay tiếng Việt, nhóm đã tìm kiếm và lựa chọn sử dụng bộ dữ liệu UIT-HWDB, được giới thiệu bởi nhóm tác giả Nghia Hieu Nguyen, Duong T. D. Vo và Kiet Van Nguyen tại hội nghị quốc tế RIVF 2022. Đây là một bộ dữ liệu benchmark được xây dựng dựa trên phương pháp chuyển đổi độc đáo để tạo ra các hình ảnh chữ viết tay tổng hợp nhưng vẫn giữ được các thuộc tính tự nhiên và đặc trưng quan trọng của dữ liệu.

Dưới đây là một số mẫu từ bộ dữ liệu:



Hình 1: Ảnh cắt theo từng dòng

Về chất lượng, UIT-HWDB khắc phục được nhược điểm của các bộ dữ liệu trước đây vốn thường chỉ đơn thuần nối các tọa độ nét bút (pen strokes) khiến hình ảnh thiếu đi tính thực tế. Bộ dữ liệu này cung cấp một nguồn tài nguyên chất lượng cao, có độ phức tạp lớn và mô phỏng sát sao các biến thể trong phong cách viết tay thực tế của người Việt.

Với việc được công bố trên nền tảng IEEE và kiểm chứng qua nhiều thực nghiệm với các phương pháp State-of-the-art (SOTA), UIT-HWDB đảm bảo tính tin cậy và hiệu quả trong việc đánh giá khả năng nhận dạng của các mô hình học máy, đặc biệt là đối với các ký tự có dấu thanh và dấu phụ phức tạp trong tiếng Việt.

Thành phần dữ liệu	Số lượng mẫu	Định dạng
UIT-HWDB-word	110,745	Ảnh cắt theo từng từ
UIT-HWDB-line	7,273	Ảnh cắt theo dòng
UIT-HWDB-paragraph	1,144	Ảnh nguyên đoạn văn bản

Bảng 3: Thống kê chi tiết bộ dữ liệu UIT-HWDB

2.2.2 Dữ liệu mở rộng

Để đáp ứng mục tiêu giải quyết bài toán thực tế tại Việt Nam, việc chỉ sử dụng các bộ dữ liệu học thuật là chưa đủ, do dữ liệu thực tiễn thường chứa nhiều nhiễu và biến thể phức tạp hơn so với các bộ dữ liệu chuẩn. Nhằm **đa dạng hóa tập huấn luyện** và thực hiện **chuẩn hóa dữ liệu** theo yêu cầu riêng của đề án, nhóm triển khai thu thập bổ sung thông qua các phương thức sau:

- **Dữ liệu viết tay tự thu thập:** Các thành viên trong nhóm trực tiếp tạo mẫu văn bản với nhiều phong cách khác nhau, từ chữ viết cẩn thận đến viết nhanh (chữ thẩu). Đồng thời, nhóm chủ động mô phỏng các điều kiện môi trường không lý tưởng như ánh sáng yếu, góc

chụp biến dạng, hoặc nền giấy đa dạng (giấy kẻ ngang, giấy ô ly) để tăng cường độ bền bỉ (robustness) cho mô hình.

- **Dữ liệu từ các nguồn hỗn hợp:** Thu thập từ văn bản in, sách báo và các biểu mẫu hành chính. Nguồn dữ liệu này không chỉ làm phong phú tập huấn luyện mà còn cung cấp cấu trúc ngữ pháp và chính tả chuẩn mực, giúp mô hình cải thiện khả năng hậu xử lý và sửa lỗi dựa trên ngữ cảnh.

Nhằm tối ưu thời gian và đảm bảo tính chính xác, nhóm thực hiện **gán nhãn bán tự động**. Quy trình thực hiện qua 3 bước:

- **Bước 1:** Sử dụng công cụ [PPOCRLabel](#) để nhận diện nội dung văn bản sơ bộ cho các hình ảnh mới thu thập.
- **Bước 2:** Các thành viên tiến hành rà soát thủ công toàn bộ kết quả từ Bước 1. Những sai sót về nội dung sẽ được điều chỉnh trực tiếp để đảm bảo nhãn đạt độ chính xác tuyệt đối.
- **Bước 3:** Toàn bộ dữ liệu sau khi kiểm tra được lưu trữ trên Google Drive của nhóm, cấu trúc lưu trữ được trình bày cụ thể bên dưới.

2.2.3 Không gian lưu trữ và cấu trúc dữ liệu

Dữ liệu tổng hợp sẽ được lưu trữ tại [IntroToML Dataset](#) ở trên Drive với cấu trúc:

- **Manual:** Dữ liệu do nhóm chuẩn bị.
- **UIT:** Dữ liệu có sẵn.

Với mỗi thư mục con, cấu trúc dữ liệu sẽ bao gồm:

- **Thư mục hình ảnh:** Chứa các tệp tin ảnh đầu vào (*.jpg, *.png).
- **Tệp nhãn:** Một tệp tin duy nhất có tên `label.json` chứa thông tin gán nhãn cho toàn bộ ảnh trong thư mục đó, có định dạng JSON tiêu chuẩn, lưu trữ dưới dạng các **cặp khóa - giá trị**:
 - **Khóa:** Tên tệp hình ảnh (1.jpg,...).
 - **Giá trị:** Chuỗi ký tự Unicode tương ứng với nội dung chữ viết tay trong ảnh.

3 Quy trình làm sạch và tiền xử lý dữ liệu

Nhóm thiết kế một notebook để thực hiện các công việc bên dưới, mã nguồn được trình bày rõ ràng, tham khảo ở [Preprocessing notebook](#).

3.1 Quy trình kiểm tra sự nhất quán

Nhóm triển khai quy trình kiểm soát tính hiện diện của dữ liệu đặc trưng. Cụ thể, script được thiết kế để thực hiện quét toàn bộ các thư mục hình ảnh (mount đến Drive của nhóm) để xác định sự tồn tại của tệp `label.json`. Trong trường hợp thư mục không chứa tệp nhãn tương ứng, thư mục đó sẽ bị loại bỏ khỏi tập dữ liệu huấn luyện nhằm đảm bảo tính toàn vẹn của cấu trúc đầu vào.

3.2 Quy trình xử lý dữ liệu bị thiếu

Sau khi xác lập tính nhất quán về sự tồn tại của tệp, bước kế tiếp tập trung vào việc đối soát số lượng thực tế. Quy trình này kiểm tra xem tổng số lượng hình ảnh trong mỗi thư mục có khớp hoàn toàn với số lượng mục nhãn (entries) được định nghĩa trong tệp `label.json` hay không. Các trường hợp phát hiện sự sai lệch (thiếu nhãn cho ảnh hoặc thừa nhãn so với dữ liệu ảnh hiện có) đều dẫn đến việc loại bỏ thư mục đó để tránh gây nhiễu cho mô hình học máy.

4 Đảm bảo chất lượng dữ liệu

Dữ liệu huấn luyện từ bộ **UIT-HWDB-dataset** được nhóm ưu tiên sử dụng nhờ các tiêu chuẩn:

- Hình ảnh sắc nét, kích thước được tối ưu hóa để giữ nguyên các đặc trưng nét chữ mà không làm tăng chi phí tính toán.
- Tập dữ liệu bao gồm nhiều phong cách viết tay từ chữ viết chuẩn, nét chữ đa dạng đến chữ viết tháu.
- Nhãn dữ liệu đảm bảo khớp hoàn toàn với nội dung văn bản trong ảnh.

Chú thích: Nhóm đã thử sử dụng mô hình **GLM-OCR 0.9B**. Qua quá trình thực hiện *fine-tuning* bằng kỹ thuật **LoRA** trên 500 mẫu ảnh từ UIT-HWDB-dataset, hiệu quả dự đoán đã được cải thiện rõ rệt, thể hiện qua việc giảm đáng kể chỉ số lỗi ký tự (CER). Vì một số lý do liên quan đến

API key cũng như độ hoàn thiện, fine-tuning notebook chưa được nhóm trích dẫn trong báo cáo này, bên dưới là một số cài đặt thông số LoRA (tham khảo tại [GLM-OCR Fine-tuning Guide](#)):

Thông số	Giá trị
<code>per_device_train_batch_size</code>	4
<code>gradient_accumulation_steps</code>	4
<code>learning_rate</code>	1.0×10^{-4}
<code>num_train_epochs</code>	3
<code>lr_scheduler_type</code>	cosine
<code>warmup_ratio</code>	0.1
<code>bf16</code>	true
<code>ddp_timeout</code>	180,000,000

Bảng 4: Cấu hình thông số kỹ thuật quá trình Fine-tuning LoRA

5 Lưu trữ và quản lý dữ liệu

Hệ thống dữ liệu của nhóm được tổ chức lưu trữ ở [IntroToML Dataset](#) trên nền tảng Google Drive

5.1 Dữ liệu gốc

- Dữ liệu nhóm được phân chia thành phân mục tương ứng với các mục mà thành viên đã chuẩn bị (100 ảnh/thành viên), bao gồm các tệp ảnh và tệp `label.json` đi kèm.
- UIT-HWDB-dataset được chức theo 3 loại hình văn bản (*Word*, *Line*, *Paragraph*), phân tách rõ rệt giữa hai tập `train` và `test`. Đây là cấu trúc gốc được cung cấp bởi tác giả

Dữ liệu sau đó được tổng hợp vào một thư mục `Data` duy nhất với cấu trúc chuẩn hóa để phục vụ trực tiếp cho quá trình huấn luyện, nhóm dự định sẽ dùng khoảng 10,000 đến 30,000 hình ảnh cho việc fine-tuning mô hình (dự định dùng GLM-OCR), bên dưới là cấu trúc của thư mục `Data`:

```

Data/
├── Manual/
│   ├── folder_1/
│   │   ├── image1.jpg
│   │   ├── image2.jpg
│   │   ├── ...
│   │   └── label.json
│   └── ...
└── UIT/
    ├── UIT_HWDB_line/
    │   ├── test_data
    │   └── train_data
    ├── UIT_HWDB_paragraph/
    └── UIT_HWDB_word/
    
```

5.2 Dữ liệu huấn luyện

Sau khi thực hiện quá trình **làm sạch** và **tiền xử lý** như đã nói ở trên, quá trình chuẩn bị dữ liệu cho huấn luyện được thực hiện bằng cách kết hợp dữ liệu do nhóm tự thu thập và bộ dữ liệu UIT. **Tập kiểm thử (test)** được trích xuất ngẫu nhiên **15** mẫu (word, line, paragraph) từ tập dữ liệu UIT (dự kiến kiểm thử **1000** mẫu), **tập huấn luyện (train)** sẽ sử dụng toàn bộ dữ liệu của nhóm làm nền tảng và lấy ngẫu nhiên thêm dữ liệu của UIT đến khi đủ **1000** mẫu (dự kiến huấn luyện **10000 - 30000** mẫu). Hiện tại, nhóm chuẩn bị trước 1000 train - 15 test để hoàn thiện quy trình huấn luyện (sẽ cập nhật theo kế hoạch dự kiến) và được lưu vào thư mục **Processed_data** với cấu trúc sau:

```

Processed_data/
├── Train/
│   ├── folder_1/
│   │   ├── image1.jpg
│   │   ├── image2.jpg
│   │   ├── ...
│   │   └── label.json
│   └── ...
└── Test/
    ├── folder_1/
    │   ├── image1.jpg
    │   ├── image2.jpg
    │   ├── ...
    │   └── label.json
    └── ...
    
```

6 Phân tích, khám phá dữ liệu (EDA)

Quá trình khám phá dữ liệu được thực hiện trên tập dữ liệu tổng hợp từ các nguồn thuộc bộ dữ liệu UIT-HWDB và của nhóm, bao gồm ba cấp độ thực thể: từ đơn (word), dòng văn bản (line) và đoạn văn (paragraph).

6.1 Thống kê mô tả

6.1.1 Tổng quan bộ dữ liệu

Tổng thể dữ liệu:

- **Tổng số ảnh thực tế:** 119,349 (ảnh)
- **Tổng số nhãn (labels):** 119,349 (nhãn)
- **Số nhãn duy nhất (unique labels):** 10,887 (nhãn)
- **Tổng số ký tự (chars):** 1,406,315 (ký tự)
- **Tổng số từ (words):** 349, 480 (từ)

Tên dataset	Số ảnh	Số nhãn	Ký tự TB	Từ TB
UIT_HWDB_line	7,228	7,228	67.7	15.7
UIT_HWDB_paragraph	1,144	1,144	436.7	100.0
UIT_HWDB_word	110,483	110,483	3.3	1.0
dkhoa	100	100	133.8	29.6
hnhan	100	100	79.1	18.1
qphuc	94	94	106.5	18.1
tphat	100	100	159.5	35.5
tcuong	100	100	22.9	5.5

Bảng 5: Thống kê theo từng bộ dữ liệu

6.1.2 Phân tích ký tự

Thống kê ký tự:

- **Tổng số ký tự:** 1,406,315 (ký tự)

- **Số ký tự unique:** 126 (ký tự)
- **Ký tự có dấu tiếng Việt:** 332,704 ký tự (chiếm 23.66%)

STT	Ký tự chung	Tỷ lệ	Ký tự tiếng Việt	Tỷ lệ
1	‘ ’	230,133 (16.36%)	‘đ’	31,976 (9.61%)
2	‘n’	140,772 (10.01%)	‘à’	24,820 (7.46%)
3	‘h’	101,018 (7.18%)	‘ư’	20,952 (6.30%)
4	‘t’	74,178 (5.27%)	‘á’	15,710 (4.72%)
5	‘c’	70,109 (4.99%)	‘ô’	13,382 (4.02%)
6	‘i’	65,356 (4.65%)	‘ê’	10,109 (3.04%)
7	‘g’	65,289 (4.64%)	‘ó’	9,327 (2.80%)
8	‘d’	31,976 (2.27%)	‘ạ’	9,213 (2.77%)
9	‘a’	31,601 (2.25%)	‘ă’	8,998 (2.70%)
10	‘u’	31,240 (2.22%)	‘ộ’	8,977 (2.70%)

Bảng 6: Thống kê top10 ký tự phổ biến nhất

6.1.3 Phân tích từ vựng

Thống kê từ vựng:

- **Tổng số từ:** 349,480 (từ)
- **Số từ unique:** 6,344 (từ)
- **Từ xuất hiện 1 lần:** 654 (từ)

STT	Từ vựng	Số lần xuất hiện
1	‘có’	3,695
2	‘là’	3,508
3	‘và’	3,467
4	‘của’	3,110
5	‘người’	3,031
6	‘một’	2,784
7	‘không’	2,721
8	‘”’	2,662
9	‘được’	2,504
10	‘đã’	2,404

Bảng 7: Thống kê top10 từ vựng phổ biến nhất

6.1.4 Phân tích độ phân giải ảnh

Chỉ số	Giá trị tối thiểu	Giá trị tối đa	Trung bình
Chiều rộng	22px	3000px	266px
Chiều cao	21px	2379px	109px
Aspect ratio	0.13	28.44	2.17
Dung lượng file	0.4KB	1718.4KB	16.5KB

Bảng 8: Các thông số về độ phân giải ảnh

6.1.5 Phân tích độ sáng/tối và chất lượng ảnh

Chỉ số	Giá trị tối thiểu	Giá trị tối đa	Trung bình
Độ sáng trung bình	102.3	244.9	211.8
Độ lệch chuẩn sáng	10.6	89.9	51.9
Độ nét	7.12	5040.37	704.45

Bảng 9: Các thông số về độ sáng/tối ảnh

6.2 Kiểm tra chất lượng dữ liệu

Trong quá trình xây dựng bộ dữ liệu huấn luyện cho mô hình nhận dạng chữ viết (OCR), sự cân bằng giữa dữ liệu cấp độ từ (Word-level) và cấp độ đoạn văn (Paragraph-level) đóng vai trò quyết định đến khả năng tổng quát hóa của mô hình.

Dữ liệu Word, Line buộc mô hình phải thực sự “nhìn” hình ảnh thay vì dựa vào xác suất ngôn ngữ để đoán chữ (các kiến trúc OCR hiện đại như Transformer hay CRNN tận dụng mối liên hệ giữa các từ để sửa lỗi), giúp mô hình mạnh mẽ hơn khi gặp các từ hiếm hoặc từ mượn.

Dữ liệu Paragraph mô phỏng các vấn đề thực tế như dòng chữ bị nghiêng, độ cong của trang giấy hay sự thay đổi mật độ khoảng cách giữa các từ. Nếu thiếu dữ liệu này, mô hình dễ gặp hiện tượng trôi dòng hoặc mất khả năng phân tách từ khi xử lý văn bản dài.

Việc dữ liệu Word, Line nhiều hơn Paragraph không hẳn là một khiếm khuyết. Tuy nhiên, để mô hình nắm vững cấu trúc ký tự, đạt được hiệu năng tối ưu trên các tài liệu thực tế, cần áp dụng

quy trình huấn luyện hai giai đoạn:


- Sử dụng dữ liệu Word, Line để huấn luyện cơ bản về nhận diện mặt chữ.
- Thực hiện fine-tuning với dữ liệu Paragraph để mô hình làm quen với bố cục, các độ phức tạp về dấu câu, xuống dòng, ...

Đối với các bài toán đặc thù như nhận diện chữ viết tay tiếng Việt, việc xây dựng loại dữ liệu Paragraph đủ lớn là bắt buộc để mô hình học được cách xử lý các dấu thanh và sự liên kết đặc trưng giữa các tổ hợp ký tự trong tiếng Việt.

6.3 Khám phá dữ liệu

6.3.1 Số lượng ảnh

Số lượng ảnh theo từng bộ dữ liệu




Hình 2: Số lượng ảnh theo loại dataset

Nhận xét:

- Bộ dữ liệu **word** chiếm số lượng áp đảo so với các loại khác (**line**, **paragraph**) do đặc thù cấu trúc theo từng từ, góp phần giúp mô hình học rất tốt các đặc trưng nhận dạng ký tự và từ vựng cơ bản.
- Các tập dữ liệu do các thành viên nhóm tự thu thập có quy mô số lượng nhỏ hơn rất nhiều so với bộ dữ liệu có sẵn, tuy nhiên các tập dữ liệu này đóng vai trò quan trọng trong việc bổ sung tính đa dạng cho dữ liệu huấn luyện (chữ viết tay thực tế khác nhau, điều kiện chụp/scan khác nhau). Điều này giúp mô hình tổng quát hóa tốt hơn và tránh hiện tượng overfitting khi chỉ huấn luyện trên một bộ dữ liệu phân bố đồng nhất như UIT_HWDB.

6.3.2 Phân bố theo độ dài nhãn

Phân bố độ dài label



Hình 3: Phân bố độ dài label

Nhận xét:


- Thông qua các điểm ngoại lai (outliers) trên Boxplot, có thể thấy xuất hiện một số nhãn có chiều dài vượt trội hoặc ngắn bất thường so với phân bố chung của nhóm đó (paragraph ngắn

hơn line). Cung cấp thêm góc nhìn về tính “nhiều” của dữ liệu tự nhiên, vừa là bài toán đặt ra cho sự ổn định của kiến trúc mô hình sau này (cần phải xử lý trước khi đưa vào mô hình huấn luyện).

- Do dữ liệu của nhóm tự chuẩn bị là dữ liệu **tổng hợp** (word, line, paragraph) để sẽ có phân bố rộng hơn so với các bộ dữ liệu chuẩn theo từng loại của UIT_HWDB.

6.3.3 Tỷ lệ ký tự có dấu

Tỷ lệ ký tự tiếng Việt có dấu (%)



Hình 4: Tỷ lệ ký tự tiếng Việt có dấu


Nhận xét:

- Tỷ lệ ký tự có dấu phân bố khá đồng đều xuyên suốt giữa các tập dữ liệu, sự đồng nhất trong quá trình thu thập tuân theo đúng quy luật bối cảnh ngôn ngữ tự nhiên của tiếng Việt, đảm bảo chất lượng và độ tin cậy của bộ dữ liệu tay mà nhóm đã đóng góp.
- Việc số lượng ký tự có dấu xuất hiện dày đặc đặt ra yêu cầu cho mô hình học máy phải có khả năng trích xuất đặc trưng không gian cực tốt để nhận diện các chi tiết rất nhỏ. Đồng

thời, cũng nên chú ý đến các yếu tố về ảnh (mờ, nhiễu, độ phân giải, ...) cũng có thể ảnh hưởng đến khả năng trích xuất ký tự có dấu tiếng Việt.


6.3.4 Phân tích ký tự

Top 10 ký tự xuất hiện nhiều nhất



Hình 5: Top10 ký tự xuất hiện nhiều nhất

Top 10 ký tự tiếng Việt (Có dấu)



Hình 6: Top10 ký tự tiếng Việt (có dấu)



Hình 7: 50 từ phổ biến nhất

Nhận xét:


- Sự xuất hiện vượt trội của ký tự khoảng trắng minh chứng rằng kho dữ liệu chủ yếu tập trung

phân bố ở cấp độ dòng (line) và đoạn văn (paragraph) mang tính liên mạch, thay vì chỉ là các từ rời rạc (words). Khôi phục chính xác khoảng trắng là yếu tố quan trọng để mô hình chia tách đúng ranh giới từ.

- Các phụ âm như **n**, **h**, **t**, **c**, **g** nằm ở top đầu (là do cấu trúc ngôn ngữ tiếng Việt phụ thuộc rất nhiều vào các tổ hợp phụ âm ghép (nh, th, ch, ng, tr,...)). Tần suất cao này giúp mô hình dễ dàng học được các nét đặc trưng cơ bản của hệ thống chữ Latinh.
- Việc ghi nhận lượng lớn các ký tự tiếng Việt cho thấy độ phủ cấu trúc âm tiết rất tốt của bộ dữ liệu. Nhưng cũng đặt ra bài toán khó cho mô hình OCR là cần có kiến trúc trích xuất đặc trưng không gian đủ tinh tế để không làm mất/mờ các dấu chấm, dấu ngã nhỏ nằm trên gạch nối của chữ cái biên độ hẹp.
- Tần suất xuất hiện nhiều của các từ nối hay đại từ cho thấy tập dữ liệu mang tính liên kết ngữ nghĩa rất cao. Việc chứa các câu văn có cấu trúc ngữ pháp hoàn chỉnh thay vì các từ ghép ngẫu nhiên là một lợi thế cực lớn cho việc huấn luyện mô hình.


6.3.5 Độ sáng và độ nét của ảnh

Phân bố độ sáng trung bình theo bộ dữ liệu



Hình 8: Phân bố độ sáng trung bình


Phân bố độ nét ảnh theo bộ dữ liệu



Hình 9: Phân bố độ nét ảnh

Nhận xét: Tập dữ liệu của nhóm thu thập có sự phân bố độ sáng/nét rộng hơn bởi do các ảnh được chụp bằng camera điện thoại, chịu ảnh hưởng bởi ánh sáng môi trường, bóng râm hoặc chất lượng giấy khác nhau so với bộ dữ liệu chuẩn UIT_HWDB (tương đối ổn định).

6.3.6 Một số dữ liệu mẫu



Hình 10: Một số dữ liệu mẫu

Tài liệu

- [1] Nghia Hieu Nguyen, Duong T. D. Vo, and Kiet Van Nguyen. UIT-HWDB: using transferring method to construct A novel benchmark for evaluating unconstrained handwriting image recognition in vietnamese. In *RIVF International Conference on Computing and Communication Technologies, RIVF 2022, Ho Chi Minh City, Vietnam, December 20-22, 2022*, pages 659–664. IEEE, 2022.