

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN - ĐẠI HỌC QUỐC GIA TP HCM

KHOA CÔNG NGHỆ THÔNG TIN

CSC14005 - Nhập môn học máy



ĐỒ ÁN

MACHINE LEARNING

Lớp: 23KHDL1

Sinh viên:

Lê Quang Phúc - 23127102

Nguyễn Quang Đăng Khoa - 23127212

Đoàn Thành Phát - 23127241

Trần Tiến Cường - 23127332

Trần Hữu Nhân - 23127442

Giảng viên hướng dẫn:

Thầy Bùi Tiến Lên

Thầy Lê Nhựt Nam

Thầy Võ Nhật Tân

2 tháng 2 năm 2026

Mục lục

BẢNG PHÂN CÔNG	1
1 Xác định và phân tích	2
1.1 Bối cảnh	2
1.2 Ý nghĩa trong bối cảnh Việt Nam	2
1.3 Mô tả bài toán	3
1.4 Kế hoạch triển khai	4
2 Chuẩn bị dữ liệu	4
2.1 Dữ liệu có sẵn	5
2.1.1 Mô tả dữ liệu	5
2.1.2 Cấu trúc và nhãn dữ liệu	5
2.2 Thu thập dữ liệu	6
TÀI LIỆU	7

BẢNG PHÂN CÔNG

GitHub: [IntroToML Repository](#).

Kế hoạch làm việc: [IntroToML Timeline](#).

STT	Họ và tên	MSSV	Công việc đảm nhiệm	Hoàn thành
1	Lê Quang Phúc	23127102	Xác định & Phân tích vấn đề	100%
2	Nguyễn Quang Đăng Khoa	23127212	Chuẩn bị dữ liệu	100%
3	Đoàn Thành Phát	23127241	Chuẩn bị dữ liệu	100%
4	Trần Tiến Cường	23127332	Xác định & Phân tích vấn đề	100%
5	Trần Hữu Nhân	23127442	Tổng hợp nội dung Proposal	100%

Bảng 1: Bảng phân công nhiệm vụ và đánh giá thành viên

1 Xác định và phân tích

1.1 Bối cảnh

Hiện nay, các hệ thống lưu trữ điện tử đang phát triển mạnh, song số lượng văn bản giấy vẫn đang đóng vai trò chủ đạo trong nhiều quy trình nghiệp vụ trong cuộc sống ngày nay. Sự tồn tại song song giữa nhu cầu số hóa dữ liệu khổng lồ và phương thức lưu trữ truyền thống đã tạo nên một thách thức đối với cơ sở hạ tầng công nghệ thông tin.

Nhận dạng ký tự quang học (OCR - Optical Character Recognition) chính là giải pháp cốt lõi cho thách thức này. Về bản chất, OCR là công nghệ chuyển đổi các định dạng dữ liệu hình ảnh (như tài liệu scan, ảnh chụp văn bản giấy) thành dữ liệu văn bản có thể máy tính có thể hiểu, chỉnh sửa và lưu trữ trong các cơ sở dữ liệu số.

Từ đây, nhóm đề xuất phát triển một hệ thống OCR chuyên biệt, tập trung tối ưu hóa khả năng nhận dạng Tiếng Việt, đặc biệt là về hình ảnh có chữ viết tay. Giải pháp này hướng tới việc giải quyết các bài toán thực tế của xã hội, hỗ trợ chuyển đổi hiệu quả nguồn tài liệu phi cấu trúc thành dữ liệu số có khả năng lưu trữ, truy xuất và khai thác giá trị cao.

1.2 Ý nghĩa trong bối cảnh Việt Nam

- **Thách thức ngôn ngữ:** Tiếng Việt là ngôn ngữ đơn âm tiết với hệ thống 6 thanh điệu và nhiều dấu phụ. Các giải pháp OCR mã nguồn mở phổ biến trên thế giới (TesseractOCR, EasyOCR,...) thường hoạt động tốt với tiếng Anh hoặc chữ in, nhưng độ chính xác khá thấp khi gặp chữ viết tay, đặc biệt là viết bằng tiếng Việt do có sự khác biệt lớn trong nét chữ và sự khó khăn trong việc xác định đúng các dấu thanh.
- **Chuyển đổi dữ liệu:** Hiện tại, việc số hóa số lượng lớn biểu mẫu viết tay chủ yếu đều dựa vào con người nhập liệu lại một cách thủ công. Quy trình này sẽ tốn kém thời gian, đòi hỏi chi phí nhân sự lớn và dễ gây sai sót, làm chậm tiến độ chuyển đổi số của các tổ chức.
- **Bảo tồn văn hóa:** Tại Việt Nam, vẫn còn nhiều tư liệu lịch sử, tác phẩm, văn bản mang nhiều giá trị nhưng vẫn đang tồn tại dưới dạng viết tay độc bản. Một hệ thống OCR hiệu

quả sẽ trở thành công cụ để hỗ trợ cho các nhà nghiên cứu số hóa, lưu trữ và khai thác, việc có thể tiếp cận và lưu trữ lại được lượng lớn thông tin như vậy không chỉ góp phần phát triển về kinh tế - xã hội mà còn mang ý nghĩa về mặt văn hóa cho Việt Nam.

1.3 Mô tả bài toán

Dưới góc độ kỹ thuật, bài toán Xây dựng hệ thống OCR chuyên biệt, tập trung tối ưu hóa khả năng nhận dạng Tiếng Việt, đặc biệt là về hình ảnh có chữ viết tay được định nghĩa là một bài toán **Học máy có giám sát**, cụ thể là bài toán **Sequence-to-Sequence** kết hợp giữa Thị giác máy tính và Xử lý ngôn ngữ tự nhiên.

- **Đầu vào (X):** Là một hình ảnh I chứa văn bản tiếng Việt (dòng chữ viết tay hoặc đoạn văn bản). Hình ảnh này thuộc dạng dữ liệu phi cấu trúc:

$$X = \{I \mid I \in \mathbb{R}^{H \times W \times C}\}$$

(Trong đó H, W, C lần lượt là chiều cao, chiều rộng và số kênh màu của ảnh).

- **Đầu ra (Y):** Là chuỗi ký tự S tương ứng với nội dung văn bản trong ảnh, thuộc tập từ vựng tiếng Việt (bao gồm chữ cái, dấu thanh, dấu câu và chữ số):

$$Y = \{s_1, s_2, \dots, s_T \mid s_t \in V\}$$

(Trong đó V là bộ từ vựng tiếng Việt, T là độ dài của chuỗi ký tự).

- **Mục tiêu:** Đề tài hướng tới việc xây dựng một giải pháp OCR hoàn chỉnh thông qua các mục tiêu cụ thể sau:

- **Tối ưu hóa mô hình:** Tìm kiếm hàm ánh xạ f_θ với bộ tham số θ^* sao cho tối thiểu hóa hàm mất mát $\mathcal{L}$ giữa chuỗi dự đoán và thực tế:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(f_\theta(X), Y)$$

1.4 Kế hoạch triển khai

Quy trình xây dựng giải pháp và triển khai ứng dụng được nhóm chia thành ba giai đoạn:

- **Giai đoạn 1 - Đánh giá và lựa chọn:** Khảo sát, thực nghiệm và so sánh hiệu năng trên các kiến trúc OCR tiên tiến hiện nay để xác định mô hình nền tảng (Base model) tối ưu cho ngôn ngữ Tiếng Việt. Nhóm dự kiến tập trung đánh giá các mô hình tiêu biểu như:
 - *Mô hình truyền thống và Hybrid:* **PaddleOCR** (với sự kết hợp của PP-OCRv4).
 - *Mô hình Vision-Language:* **DeepSeek-OCR** (version 1).
 - *Mô hình kết hợp (Pipeline):* Sử dụng **YOLO** để phát hiện vùng văn bản (Text Detection) kết hợp với các bộ giải mã (Decoder) chuyên biệt cho nhận dạng chữ viết tay.
- **Giai đoạn 2 - Fine-tuning:** Tiến hành tinh chỉnh mô hình đã lựa chọn trên tập dữ liệu chữ viết tay tiếng Việt đặc thù. Quá trình này tập trung vào việc xử lý các thách thức về nét chữ biến thiên, dấu thanh phức tạp và cấu trúc văn bản phi cấu trúc, nhằm tối ưu hóa các chỉ số CER (Character Error Rate) và WER (Word Error Rate).
- **Giai đoạn 3 - Triển khai và tối ưu hóa ứng dụng:** Đóng gói mô hình và triển khai thành một nền tảng trực tuyến (Web-based platform). Hệ thống sẽ được tối ưu hóa về tốc độ phản hồi và giao diện người dùng, cung cấp một giải pháp hoàn chỉnh cho việc OCR cho tài liệu tiếng Việt một cách trực quan và hiệu quả.

2 Chuẩn bị dữ liệu

Chất lượng và độ đa dạng của dữ liệu được xem là yếu tố tiên quyết quyết định hiệu năng của mô hình. Đối với bài toán OCR tiếng Việt, thách thức không chỉ nằm ở việc nhận diện ký tự mà còn phải xử lý được sự thay đổi vô cùng lớn của nét chữ viết tay cá nhân cùng hệ thống dấu thanh. Do đó, nhóm không chỉ dựa vào một nguồn dữ liệu duy nhất mà kết hợp giữa nhiều nguồn dữ liệu chuẩn và dữ liệu thực tế tự thu thập thêm để đảm bảo mô hình có khả năng tổng quát hóa tốt nhất.

2.1 Dữ liệu có sẵn

Dữ liệu cho quá trình huấn luyện được nhóm xây dựng dựa trên bộ UIT-HWDB: [UIT-HWDB](#) [1]. Đây là bộ dữ liệu chuẩn uy tín cho cộng đồng nghiên cứu nhận dạng chữ viết tay tiếng Việt, bao gồm hàng ngàn mẫu chữ viết tay tự nhiên. Việc sử dụng UIT-HWDB không chỉ giúp nhóm đảm bảo tính chính xác về mặt khoa học cho dữ liệu đầu vào mà còn tạo ra một cơ sở tham chiếu khách quan, cho phép so sánh hiệu quả của giải pháp đề xuất với các nghiên cứu trước đó.

2.1.1 Mô tả dữ liệu

Bộ dữ liệu được chia thành 3 cấp độ nhận dạng chính: **Từ (Word)**, **Dòng (Line)**, và **Đoạn văn (Paragraph)**, giúp đánh giá toàn diện khả năng của mô hình từ đơn giản đến phức tạp.

Thành phần dữ liệu	Số lượng mẫu	Định dạng
UIT-HWDB-word	110,745	Ảnh cắt theo từng từ
UIT-HWDB-line	7,273	Ảnh cắt theo dòng
UIT-HWDB-paragraph	1,144	Ảnh nguyên đoạn văn bản

Bảng 2: Thống kê chi tiết bộ dữ liệu UIT-HWDB

2.1.2 Cấu trúc và nhãn dữ liệu

Được tổ chức phân cấp rõ ràng để thuận tiện cho quá trình huấn luyện và đánh giá mô hình. Mỗi mức độ nhận dạng (từ, dòng, đoạn văn) được chia thành hai tập dữ liệu con riêng biệt: tập huấn luyện và tập kiểm thử.

Trong mỗi thư mục con (train/test), dữ liệu được bố trí như sau:

- **Thư mục hình ảnh:** Chứa các tệp tin ảnh đầu vào (*.jpg).
- **Tệp nhãn:** Một tệp tin duy nhất có tên `label.json` chứa thông tin gán nhãn cho toàn bộ ảnh trong thư mục đó, có định dạng JSON tiêu chuẩn, lưu trữ dưới dạng các **cặp khóa - giá trị**:
 - **Khóa:** Là tên tệp hình ảnh (1.jpg,...).
 - **Giá trị:** Là chuỗi ký tự Unicode tương ứng với nội dung chữ viết tay trong ảnh.

2.2 Thu thập dữ liệu

Tuy nhiên, để giải quyết bài toán thực tiễn Việt Nam như mục tiêu đề án đề ra, chỉ sử dụng dữ liệu học thuật là chưa đủ, bởi dữ liệu thực tế chứa nhiều nhiều hơn so với bộ dữ liệu chuẩn. Nhằm để **mở rộng và làm đa dạng hóa dữ liệu** cũng như là tham gia vào quá trình **chuẩn hóa dữ liệu** thì nhóm dự định sẽ thực hiện thêm các phương pháp tự thu thập thêm:

- **Dữ liệu viết tay:** Các thành viên sẽ cùng nhau tạo nên bộ dữ liệu để bổ sung các phong cách viết chữ đa dạng, từ nắn nót đến viết tháu, đồng thời mô phỏng các điều kiện chụp ảnh không lý tưởng (ánh sáng yếu, góc chụp nghiêng, giấy ô ly,...) mà ứng dụng thực tế sẽ phải đối mặt.
- **Nguồn dữ liệu khác:** Đến từ văn bản in và tài liệu hỗn hợp (sách báo, vở ghi chép, văn bản hành chính), giúp cung cấp sự chính xác về ngữ pháp, chính tả và cấu trúc câu hoàn chỉnh góp phần giúp cho mô hình có khả năng tự sửa lỗi dựa trên ngữ cảnh tốt hơn.

Quá trình gán nhãn: Để xử lý lượng dữ liệu tự thu thập một cách hiệu quả và chính xác, thay vì thực hiện gán nhãn thủ công hoàn toàn tốn kém thời gian, nhóm thực hiện **gán nhãn bán tự động** với sự hỗ trợ của các công cụ có sẵn. Quy trình dự kiến bao gồm các bước:

- **Bước 1:** Nhóm dự kiến sử dụng công cụ **PPOCRLLabel** để thực hiện khởi tạo nhãn nhận dạng sơ bộ cho phép đề xuất nội dung văn bản ban đầu cho từng hình ảnh.
- **Bước 2:** Các thành viên trong nhóm đóng vai trò là người kiểm định. Dựa trên kết quả sơ bộ, nhóm tiến hành rà soát và chỉnh sửa các sai sót thủ công để đảm bảo nhãn dữ liệu chính xác tuyệt đối với nội dung trên ảnh.
- **Bước 3:** Dữ liệu sau khi gán nhãn thủ công được xuất ra định dạng chuẩn sẵn sàng cho quá trình huấn luyện.

Tài liệu

- [1] Nghia Hieu Nguyen, Duong T. D. Vo, and Kiet Van Nguyen. UIT-HWDB: using transferring method to construct A novel benchmark for evaluating unconstrained handwriting image recognition in vietnamese. In *RIVF International Conference on Computing and Communication Technologies, RIVF 2022, Ho Chi Minh City, Vietnam, December 20-22, 2022*, pages 659–664. IEEE, 2022.